

# Parte 2B

## Distribuições contínuas

# Distribuições contínuas

Variáveis aleatórias e leis de probabilidade.  
Medidas de localização, dispersão e forma.  
Distribuições univariadas mais comuns.  
Pares aleatórios e vectores aleatórios.  
Distribuição normal bivariada.  
Transformação uniformizante e mais simulação.

# Variável aleatória e função de distribuição (revisão)

Seja  $(\Omega, \mathcal{A}, P)$  um espaço de probabilidades.

**Variável aleatória** é uma função  $X: \Omega \rightarrow \mathbb{R}$

tal que  $X^{-1}(B) \in \mathcal{A}, \forall B \in \mathcal{B}$ ; então  $P(X \in B) = P(X^{-1}(B))$


A **função de distribuição** (fd) de uma v.a.  $X$  é definida por

$$F(x) = P(X \leq x), x \in \mathbb{R}$$

Se o contradomínio de  $X$  for um conjunto infinito não numerável (e.g., um intervalo,  $\mathbb{R}^+$ ,  $\mathbb{R}$ , ...), a v.a.  $X$  é **não discreta**. Neste caso, se existir uma função  $f: \mathbb{R} \rightarrow \mathbb{R}$  que desempenhe um papel análogo ao da fmp (chamada **função densidade de probabilidade**), a v.a. diz-se **absolutamente contínua**.

## caso discreto

$$f(x) = \begin{cases} P(X = x) & , x \in \{x_1, x_2, \dots\} \\ 0 & , x \notin \{x_1, x_2, \dots\} \end{cases}$$




$$(i) \quad p_i \geq 0$$

$$(ii) \quad \sum_i p_i = 1 \quad \text{soma unitária}$$

$$(iii) \quad P(X \in B) = \sum_{i: x_i \in B} P(X = x_i)$$

## caso absol. contínuo

$$f(x) = 0, \text{ se } x \notin \text{supp}(X)$$



$$(i) \quad f(x) \geq 0$$

$$(ii) \quad \int_{-\infty}^{+\infty} f(x) dx = 1 \quad \text{área unitária}$$

$$(iii) \quad P(X \in B) = \int_B f(x) dx$$

probabilidades são integrais (áreas)

## fmp / fdp (massa de probabilidade / densidade de probabilidade)

As v.a. **discretas** são as que têm suporte contável,  $\{x_1, x_2, x_3, \dots\}$ . Ficam identificadas pela **fmp** (função massa de probabilidade).

**fmp**

$$p_i = f(x_i) = P(X = x_i)$$

tal que

$$p_i \geq 0; \sum_i p_i = 1$$

As v.a. **absolutamente contínuas** têm suporte infinito não numerável. Ficam identificadas por uma **fdp** (função densidade de probabilidade).

**fdp**

$$f: \mathbb{R} \rightarrow \mathbb{R}$$
$$x \mapsto f(x)$$

tal que


$$f(x) \geq 0; \int_{\mathbb{R}} f(x) dx = 1$$

# Distribuições (absolutamente) contínuas

Uma v.a.  $X$  diz-se **absolutamente contínua** se existir uma fdp  $f: \mathbb{R} \rightarrow \mathbb{R}$ , tal que

$$F(x) = P(X \leq x) = \int_{-\infty}^x f(t) dt$$

Então  $F'(x) = f(x)$  e  $P(a < X \leq b) = \int_a^b f(x) dx = F(b) - F(a)$



Recorde-se que uma v.a.  $X$  (discreta, contínua, ou outra) fica identificada pela **função de distribuição** (fd),  $F(x) = P(X \leq x)$ ,  $x \in \mathbb{R}$

As fd têm as seguintes propriedades, que as caracterizam:

são não decrescentes, contínuas à direita e  $\lim_{x \rightarrow -\infty} F(x) = 0$ ,  $\lim_{x \rightarrow +\infty} F(x) = 1$

- No caso discreto,

$$F(x) = \sum_{i: x_i \leq x} p_i$$

↓

função em escada (saltos  $p_i$  nos pontos  $x_i$ )

- No caso contínuo,

$$F(x) = \int_{-\infty}^x f(y) dy$$

↓

função contínua,  $F'(x) = f(x)$ ,  
nos pontos de continuidade de  $f$

Em qualquer caso  
(discreto, contínuo, ou outro)

$$P(a < X \leq b) = F(b) - F(a)$$

# Variáveis aleatórias (absol.) contínuas

- Têm suporte infinito não numerável
- Ficam identificadas pela fdp  $f: \mathbb{R} \rightarrow \mathbb{R}$  que satisfaz a

$$(i) \quad f(x) \geq 0$$

$$(ii) \quad \int_{-\infty}^{+\infty} f(x) dx = 1$$

$$(iii) \quad P(X \in B) = \int_B f(x) dx$$

O conhecimento da fdp equivale ao da fd pois dada uma fdp  $f$  temos  $F(x) = \int_{-\infty}^x f(y) dy$  e dada uma fd  $F$  temos  $f(x) = F'(x)$  nos pontos de continuidade de  $f$ .



## Notas:

1. O valor  $f(x)$  da fdp num determinado ponto  $x$  não representa uma probabilidade (as probabilidades são integrais = áreas). De facto,  $P(X = x) = \int_{\{x\}} f(t) dt = 0$
2. As fdp podem ter valores superiores a 1, e.g., fdp  $f(x) = 2 I_{[0, 0.5]}(x)$  \* e não têm que ser contínuas para todo o  $x$  (podem até não estar definidas em alguns pontos)
3. No caso contínuo (contrariamente ao caso discreto), tem-se  
$$P(a < X \leq b) = P(a \leq X \leq b) = P(a \leq X < b) = P(a < X < b) = \int_a^b f(x) dx$$

---

\* A função indicatriz do conjunto  $A$  é dada por 
$$I_A(x) = \begin{cases} 1 & , se \ x \in A \\ 0 & , se \ x \notin A \end{cases}$$



# Distribuições (absolutamente) contínuas

- distribuição uniforme num intervalo
- distribuição exponencial de parâmetro  $\lambda$   
*durações de vida, intervalos de tempo entre ocorrências de fenómenos consecutivos (está relacionada com a Poisson)*
- distribuição normal (ou gaussiana)  
*fenómenos que resultam de causas aditivas*

# Distribuição uniforme (contínua) – $U[a,b]$

dunif, punif, ...


$$\mu = \frac{a+b}{2}, \quad \sigma^2 = \frac{(b-a)^2}{12}$$



$$f(x) = \frac{1}{b-a}, \quad a < x < b$$

$$F(x) = \begin{cases} 0 & , \quad x < a \\ \frac{x-a}{b-a} & , \quad a \leq x < b \\ 1 & , \quad x \geq b \end{cases}$$

Dedução da f.d. da  $U[a,b]$  a partir da densidade:




$$a \leq x < b \Rightarrow F(x) = \int_a^x \frac{1}{b-a} dt = \frac{x-a}{b-a} \quad (\text{área do rectângulo a amarelo})$$

$$x < a \Rightarrow F(x) = \int_{-\infty}^x 0 dt = 0; \quad x > b \Rightarrow F(x) = F(b) = 1$$


# Distribuição exponencial – $Exp(\lambda)$

dexp, pexp, ...

$$\mu = \frac{1}{\lambda}, \sigma^2 = \frac{1}{\lambda^2}$$



$$f(x) = \lambda e^{-\lambda x}, \quad x > 0$$




$$F(x) = \begin{cases} 0, & x < 0 \\ 1 - e^{-\lambda x}, & x \geq 0 \end{cases}$$

**Nota:** Esta distribuição “não tem memória”, i.e.,


$$P(X > t + y | X > t) = P(X > y), \text{ para } t > 0, y > 0$$

Dedução da f.d. da  $Exp(\lambda)$  a partir da densidade:



# Distribuição normal (ou gaussiana)

dnorm, pnorm, ...



Carl Friedrich Gauss  
1777-1855

valor médio      desvio padrão

↑      ↗

$$X \sim N(\mu, \sigma)$$

$$Z \sim N(0,1)$$


$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2}$$

$$f(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}x^2}$$


$$X = \sigma Z + \mu$$

$$Z = (X - \mu) / \sigma$$

$$P(-1.96 < Z < 1.96) = 0.9500042 \\ \cong 0.95$$



$$P(-1 < Z < 1) = 0.6826895 \\ \cong 0.683$$



### Exercício:


(a) Calcule  $P(-2 < Z < 2)$ , sendo  $Z \sim N(0,1)$ .

```
pnorm(2) - pnorm(-2)
[1] 0.9544997
```

(b) Calcule  $P(\mu - 2\sigma < X < \mu + 2\sigma)$ , sendo  $X \sim N(\mu, \sigma)$ .




Densidades normais com o mesmo valor médio e diferentes variâncias:



$$\sigma = 1 \quad \sigma = 2$$

$\sigma$  é um parâmetro de dispersão/escala

Densidades normais com diferentes valores médios e a mesma variância:



$$\mu = 0 \quad \mu = 2$$

$\mu$  é um parâmetro de localização

## Valor médio de uma v.a. $X$ (contínua)

**Valor médio** (ou **valor esperado**) de uma v.a.  $X$ , contínua, é uma “média pesada” dos valores  $x$  que a v.a. pode assumir (os pesos são os valores  $f(x)$  da fdp) e representa-se por  $E(X)$ ,  $\mu$  ou  $\mu_X$ . É dado por

$$\mu = E(X) = \int_{-\infty}^{+\infty} x f(x) dx$$

desde que este integral convirja absolutamente, i.e., desde que  $\int_{-\infty}^{+\infty} |x| f(x) dx < +\infty$

**Nota:** Há v.a. que não têm valor médio. Por exemplo, a v.a.  $X \sim \text{Cauchy}(0,1)$ , com fdp

$$f(x) = \frac{1}{\pi} \frac{1}{1+x^2}, -\infty < x < +\infty$$

pois

$$\int_{-\infty}^{+\infty} |x| \frac{1}{1+x^2} dx = +\infty$$

---

**Exemplo 21:** Cálculo do valor médio de uma v.a.  $X \sim U[a,b]$

$$\mu = E(X) = \int_a^b x \frac{1}{b-a} dx = \frac{1}{b-a} \frac{x^2}{2} \Big|_a^b = \frac{1}{b-a} \frac{b^2 - a^2}{2} = \frac{b+a}{2}$$

( $\mu$  é o ponto médio do intervalo  $[a,b]$  e o ponto de simetria da fdp)

## Valor médio de $h(X)$ , sendo $X$ contínua

Dada uma função  $h$ , definimos analogamente o valor médio da v.a.  $Y = h(X)$  por

$$E(h(X)) = \int_{-\infty}^{+\infty} h(x) f(x) dx$$

desde que este integral convirja absolutamente

## Variância e desvio padrão de $X$

variância

$$\sigma^2 = \text{var}(X) = E((X - \mu)^2) = \int_{-\infty}^{+\infty} (x - \mu)^2 f(x) dx$$

desvio padrão

$$\sigma = \sqrt{\text{var}(X)}$$

A **moda**, no caso contínuo, é o valor  $x$  tal que  $f(x)$  é máximo; há distribuições unimodais, bimodais, plurimodais e amodais.

O **coeficiente de assimetria** é definido do mesmo modo que no caso discreto, i.e.,

$$\beta_1 = E((X - \mu)^3 / \sigma^3) = \frac{1}{\sigma^3} \int_{-\infty}^{+\infty} (x - \mu)^3 f(x) dx$$

---

As fórmulas e propriedades dadas sobre valores médios, variâncias, etc. para o caso discreto mantêm-se válidas para o caso contínuo. As demonstrações são análogas, substituindo os somatórios por integrais. Assim, temos por exemplo

$$\text{var}(X) \geq 0$$

$$E(a + bX) = a + bE(X)$$

$$\text{var}(X) = E(X^2) - \mu^2$$

$$\text{var}(a + bX) = b^2 \text{var}(X)$$

$$\sigma_{a+bX} = |b| \sigma_X$$

**Exemplo 21 (cont.):** Cálculo de  $E(X^2)$  e da variância de  $X \sim U[a, b]$

$$E(X^2) = \int_a^b x^2 \frac{1}{b-a} dx = \frac{1}{b-a} \frac{x^3}{3} \Big|_a^b = \frac{1}{b-a} \frac{b^3 - a^3}{3} = \frac{b^2 + ab + a^2}{3}$$

$$\begin{aligned} \text{var}(X) &= E(X^2) - E^2(X) = \frac{b^2 + ab + a^2}{3} - \frac{(b+a)^2}{4} = \\ &= \frac{b^2 + ab + a^2}{3} - \frac{b^2 + 2ab + a^2}{4} = \frac{b^2 - 2ab + a^2}{12} = \frac{(b-a)^2}{12} \end{aligned}$$

**Exemplo 22:** Cálculo do valor médio e variância de  $X \sim \text{Exp}(\lambda)$

$$E(X) = \int_0^{+\infty} x \underbrace{\lambda e^{-\lambda x}}_{h'(x)} dx = -x e^{-\lambda x} \Big|_0^{+\infty} - \int_0^{+\infty} -e^{-\lambda x} dx = 0 - \frac{1}{\lambda} e^{-\lambda x} \Big|_0^{+\infty} = \frac{1}{\lambda}$$

$$E(X^2) = \int_0^{+\infty} x^2 \lambda e^{-\lambda x} dx = -x^2 e^{-\lambda x} \Big|_0^{+\infty} - \int_0^{+\infty} -2x e^{-\lambda x} dx = 0 + \frac{2}{\lambda} \int_0^{+\infty} \lambda x e^{-\lambda x} dx = \frac{2}{\lambda} E(X) = \frac{2}{\lambda^2};$$

$$\text{var}(X) = E(X^2) - E^2(X) = \frac{2}{\lambda^2} - \frac{1}{\lambda^2} = \frac{1}{\lambda^2}$$

Integração por partes:

$$\int h' g = h g - \int h g'$$

# Características teóricas (medidas de localização, dispersão e forma)

nome	símbolo	caso discreto	caso contínuo
valor médio* $E(X)$	$\mu$	$\sum_i x_i p_i$	$\int_{-\infty}^{+\infty} x f(x) dx$
variância* $\text{var}(X) = E((X - \mu)^2)$	$\sigma^2$	$\sum_i (x_i - \mu)^2 p_i$	$\int_{-\infty}^{+\infty} (x - \mu)^2 f(x) dx$
coef. assim.* $E((X - \mu)^3 / \sigma^3)$	$\beta_1$	$\frac{1}{\sigma^3} \sum_i (x_i - \mu)^3 p_i$	$\frac{1}{\sigma^3} \int_{-\infty}^{+\infty} (x - \mu)^3 f(x) dx$
mediana ⋮	$\chi_{1/2}$	$\inf\{x : F(x) \geq 1/2\}$	

\* existem somente se as séries/integrais convergirem absolutamente

**Exemplo 23:** Cálculo do valor médio e variância de  $Z \sim N(0,1)$

$$E(Z) = \int_{-\infty}^{+\infty} \frac{1}{\sqrt{2\pi}} x e^{-x^2/2} dx = -\frac{1}{\sqrt{2\pi}} e^{-x^2/2} \Big|_{-\infty}^{+\infty} = 0$$

$$\begin{aligned} \text{var}(Z) = E(Z^2) &= \int_{-\infty}^{+\infty} \frac{1}{\sqrt{2\pi}} x^2 e^{-x^2/2} dx = \\ &= -\frac{1}{\sqrt{2\pi}} x e^{-x^2/2} \Big|_{-\infty}^{+\infty} - \int_{-\infty}^{+\infty} -\frac{1}{\sqrt{2\pi}} e^{-x^2/2} dx = 0 + 1 = 1 \end{aligned}$$

Integração por partes:

$$\int h' g = h g - \int h g'$$



$$h'(x) = x e^{-x^2/2}, g(x) = x$$

$$h(x) = -e^{-x^2/2}, g'(x) = 1$$



## Quantil- $p$ (caso de v.a. contínua)

É o valor de  $x$  que corresponde à área acumulada  $p$  (à esquerda de  $x$  no gráfico da fdp) e representa-se por  $\chi_p$ . No caso  $p = 0.5$  temos a **mediana**




**Exercício:** Calcule a mediana da distribuição  $Exp(1)$ .

```
qexp(1/2, 1)  
[1] 0.6931472
```

```
log(2)  
[1] 0.6931472
```

$$\chi_{0.5} = F^{-1}(0.5)$$



**Exemplo 22 (cont.):** Cálculo da mediana de  $X \sim Exp(\lambda)$ , que é a solução da equação  $F(x)=1/2$ , sendo  $F(x) = 1 - e^{-\lambda x}$ ,  $x > 0$ .

$$F(x) = 1 - e^{-\lambda x} = \frac{1}{2} \Leftrightarrow e^{-\lambda x} = \frac{1}{2} \Leftrightarrow -\lambda x = -\log(2) \Leftrightarrow x = \frac{\log(2)}{\lambda}$$

Note-se que nesta distribuição temos  $\chi_{0.5} = \frac{\log(2)}{\lambda} < \frac{1}{\lambda} = \mu$  (mediana < valor médio)

## quantil- $p$ de uma v.a. $X$

Mais geralmente, o **quantil- $p$**  de uma v.a.  $X$  contínua (ou da sua distribuição) é o valor  $x$  que corresponde a uma probabilidade  $p$  acumulada à sua esquerda. Se a fd  $F$  for estritamente crescente, coincide com a inversa da fd no ponto  $p$ , i.e., com  $F^{-1}(p)$ .

Inclui os casos particulares da

**mediana**, se  $p = 1/2$


**quartis**, se  $p = 1/4, 1/2, 3/4$  (**1º, 2º e 3º quartil**)

**decis**, se  $p = i/10$ , com  $i = 1, 2, \dots, 9$  (**1º, 2º, ..., 9º decil**)

**percentis**, se  $p = i/100$ , com  $i = 1, 2, \dots, 99$  (**1º, 2º, ..., 99º percentil**)

**Exercício:** Calcule os quartis, o 3º decil e os quantis de probabilidade  $i/6$ , da distribuição

```
Exp(1)  qexp(1:3/4,1)
[1] 0.2876821 0.6931472 1.3862944
qexp(3/10,1)
[1] 0.3566749
qexp(1:5/6,1)
[1] 0.1823216 0.4054651 0.6931472
[4] 1.0986123 1.7917595
```



**Exemplo 22 (cont.):** Cálculo do quantil- $p$  de  $X \sim \text{Exp}(\lambda)$ , que é a solução da equação  $F(x) = p$ , com  $F(x) = 1 - e^{-\lambda x}$ ,  $x > 0$ .

$$p = F(x) = 1 - e^{-\lambda x} \Leftrightarrow e^{-\lambda x} = 1 - p \Leftrightarrow -\lambda x = \log(1 - p) \Leftrightarrow x = -\frac{\log(1 - p)}{\lambda}$$

Logo  $\chi_p = -\frac{\log(1 - p)}{\lambda}$

**Exercício:** Calcule os decis da distribuição  $N(0,1)$

```
qnorm(1:9/10)
```


```
[1] -1.2815516 -0.8416212 -0.5244005 -0.2533471  0.0000000  0.2533471  
[7]  0.5244005  0.8416212  1.2815516
```

São simétricos porque a distribuição  $N(0,1)$  é simétrica (em torno de 0).

se	$p = 1/2$	o quantil chama-se	mediana
	$p = 1/4, 2/4, 3/4$		quartil
	$p = 1/10, \dots, 9/10$		decil
	$p = 1/100, \dots, 99/100$		percentil


Exemplos de curvas de percentis de peso de rapazes dos 0 aos 5 anos (OMS) e dos 0 aos 2 anos (DGS, Min. Saúde).

Rapazes – **Peso 0-5 A**



RAPAZES

*peso 0-24 meses*



Fonte: DGS, Circular normativa nº 05/DSMIA

## Quantil de probabilidade $p$

No caso geral, dada uma fd  $F(\cdot)$  qualquer (discreta, contínua ou outra), o **quantil de probabilidade  $p$** , representado por  $\chi_p$ , é definido por

$$\chi_p = \inf\{x : F(x) \geq p\}$$


Esta “função quantil” definida para uma fd qualquer  $F$  é também conhecida por “**inversa generalizada**” de  $F$  (e denotada por  $F^{\leftarrow}$ ).

# Quantil de probabilidade $p$


$$\chi_p = \inf\{x : F(x) \geq p\}$$

Caso contínuo (com f.d.  $F$  crescente):

$$\chi_p = F^{-1}(p)$$



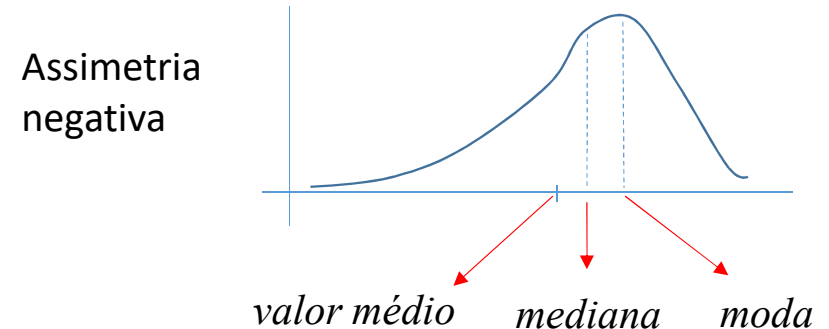

Caso discreto (fd  $F$ ):





## Notas:

1. Se  $X$  (com valor médio  $\mu$ ) for simétrica\* em torno do ponto  $a$ , e unimodal, então  $\mu = \chi_{0.5} = moda = a$
2. A assimetria de uma distribuição unimodal está relacionada com a posição relativa das seguintes 3 medidas de localização: valor médio ( $\mu$ ), mediana ( $\chi_{0.5}$ ) e moda. Em geral uma assimetria positiva ( $\beta_1 > 0$ ) corresponde à relação  $moda < \chi_{0.5} < \mu$ ; e uma assimetria negativa, a  $\mu < \chi_{0.5} < moda$




---

\* uma v.a. com fd  $F$  diz-se **simétrica em torno do ponto  $a$**  se  $F(a-x) = 1 - F(a+x)$ ,  $x \in \mathbb{R}$ .  
- no caso contínuo, equivale a ter simetria da fdp em torno de  $a$ , i.e.,  $f(a-x) = f(a+x)$ ,  $x \in \mathbb{R}$ .

**Nota:** Há v.a.  $X$  que **não são discretas nem contínuas** e que têm interesse na prática, por exemplo, para modelar o **tempo de espera num semáforo**, a **duração de uma anestesia**, a **quantidade de precipitação em dado local em certo mês do ano**, etc.. A f.d. de  $X$  nestes 3 exemplos é uma **mistura de uma v.a. discreta** com suporte  $\{0\}$  (pois o “tempo de espera no semáforo”, a “duração da anestesia” ou a “precipitação” pode ser 0, com certa probabilidade  $p$ ) **com uma v.a. contínua** positiva (pois com probabilidade  $1 - p$  esse “tempo de espera no semáforo”, etc., será positivo). Assim, a f.d. de  $X$  tem um salto de amplitude  $p$  no ponto 0 e é contínua em  $\mathbb{R} - \{0\}$ . Um exemplo concreto é a seguinte f.d.:

$$F(x) = \begin{cases} 0 & , x < 0 \\ 1 - (1 - p)e^{-\lambda x} & , x \geq 0 \end{cases}$$



Uma mistura de uma v.a. discreta com uma contínua (com f.d.  $F_d$  e  $F_c$ , respectivamente) tem f.d. da forma  $F(x) = p F_d(x) + (1 - p) F_c(x)$

# Distribuições contínuas – formulário

modelo	parâmetros	v. médio $\mu$	variância $\sigma^2$	mediana $\chi_{1/2}$	assimetria $\beta_1$
$U[a, b]$	$a < b$	$\frac{a+b}{2}$	$\frac{(b-a)^2}{12}$	$\frac{a+b}{2}$	0
$Exp(\lambda)$	$\lambda > 0$	$1/\lambda$	$1/\lambda^2$	$\frac{\log 2}{\lambda}$	2
$N(\mu, \sigma)$	$\mu \in \mathbb{R}$ $\sigma > 0$	$\mu$	$\sigma^2$	$\mu$	0

Recorde-se que	$\text{var}(X) \geq 0$	$E(a + bX) = a + bE(X)$
	$\text{var}(X) = E(X^2) - \mu^2$	$\text{var}(a + bX) = b^2 \text{var}(X)$

**Exercício: (nº 50)**

- a) Deduza a fórmula da densidade de  $Y = a + bX$  à custa da densidade de  $X$ .
- b) Recorde que o valor médio e o desvio padrão de  $Z \sim N(0,1)$  são 0 e 1 (vd. exemplo 23, slide 173). Prove que  $E(X) = \mu$  e  $\text{var}(X) = \sigma^2$ , no caso  $X \sim N(\mu, \sigma)$ .
- c) Dada uma v.a.  $X$  com valor médio  $\mu$  e desvio padrão  $\sigma$ , calcule o valor médio e o desvio padrão da v.a. padrão (ou *standard*),  $Y = (X - \mu) / \sigma$

## Resolução:

a) Dedução da fórmula da fdp de  $Y = a + bX$  à custa da fdp de  $X$ :

$$F_Y(y) = P(a + bX \leq y) = P(bX \leq y - a) = \begin{cases} P(X \leq \frac{y-a}{b}) = F_X(\frac{y-a}{b}) & , b > 0 \\ P(X \geq \frac{y-a}{b}) = 1 - F_X(\frac{y-a}{b}) & , b < 0 \end{cases}$$

$$\Rightarrow f_Y(y) = \begin{cases} \frac{d}{dy} F_X(\frac{y-a}{b}) = f_X(\frac{y-a}{b}) \frac{1}{b} & , b > 0 \\ -\frac{d}{dy} F_X(\frac{y-a}{b}) = f_X(\frac{y-a}{b}) \frac{1}{-b} & , b < 0 \end{cases} \quad \text{Logo} \quad \boxed{f_Y(y) = \frac{1}{|b|} f_X(\frac{y-a}{b})}$$

b)  $E(Z) = 0$  e  $\text{var}(Z) = 1$ . Prova-se que  $E(X) = \mu$  e  $\text{var}(X) = \sigma^2$ , no caso  $X \sim N(\mu, \sigma)$ :

$$f_X(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2} = \frac{1}{\sigma} f_Z\left(\frac{x-\mu}{\sigma}\right) \quad \text{portanto } X = \mu + \sigma Z$$

$$\text{Logo} \quad E(X) = E(\mu + \sigma Z) = \mu + \sigma E(Z) = \mu \quad \text{e}$$

$$\text{var}(X) = \text{var}(\mu + \sigma Z) = \sigma^2 \text{var}(Z) = \sigma^2$$

# Vector aleatório

É uma função  $(X_1, \dots, X_k) : \Omega \rightarrow \mathbb{R}^k$ , que a cada  $\omega \in \Omega$  faz corresponder  $(X_1(\omega), \dots, X_k(\omega))$  tal que ...

Fica identificado por uma qualquer das seguintes funções

- fmp conjunta (**c. discreto**) / fdp conjunta (**c. contínuo**);
- fd conjunta (**c. geral**):  $F(x_1, \dots, x_k) = P(X_1 \leq x_1, \dots, X_k \leq x_k)$

$X_1, \dots, X_k$  dizem-se **mutuamente independentes** se

$\forall B_1 \subset \mathbb{R}, \dots, B_k \subset \mathbb{R}$  borelianos de  $\mathbb{R}$

$$P(X_1 \in B_1, \dots, X_k \in B_k) = P(X_1 \in B_1) \dots P(X_k \in B_k)$$



as fmp/fdp conjuntas factorizam-se no produto das fmp/fdp marginais

## Par aleatório

É uma função  $(X, Y) : \Omega \rightarrow \mathbb{R}^2$ , que a cada  $\omega \in \Omega$  faz corresponder um par  $(X(\omega), Y(\omega))$  tal que ...

O par aleatório diz-se **absolutamente contínuo** se existir uma função não negativa  $f : \mathbb{R}^2 \rightarrow \mathbb{R}$  (chamada **fdp conjunta**) e com integral (em  $\mathbb{R}^2$ ) unitário, tal que

$$F(x, y) = P(X \leq x, Y \leq y) = \int_{-\infty}^x \left( \int_{-\infty}^y f(u, v) dv \right) du$$

Recorde-se que as v.a.  $X$  e  $Y$  se dizem **independentes** se para quaisquer borelianos  $A$  e  $B$  de  $\mathbb{R}$ ,

$$P(X \in A, Y \in B) = P(X \in A) P(Y \in B)$$

No caso contínuo, equivale a ter

$$f(x, y) = f_X(x) f_Y(y)$$

# Pares aleatórios contínuos


**fdp conjunta:**  $f: \mathbb{R}^2 \rightarrow \mathbb{R}$  tal que  $f(x, y) \geq 0$  e  $\int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} f(x, y) dx dy = 1$

**fd conjunta:**  $F(x, y) = P(X \leq x, Y \leq y) = \int_{-\infty}^x \left( \int_{-\infty}^y f(u, v) dv \right) du$

$$\frac{\partial^2 F(x, y)}{\partial x \partial y} = f(x, y)$$

$$P((X, Y) \in B) = \iint_B f(x, y) dx dy$$

$$\begin{aligned} P(a < X \leq b, c < Y \leq d) &= \int_a^b \int_c^d f(x, y) dx dy = \\ &= F(b, d) - F(a, d) - F(b, c) + F(a, c) \end{aligned}$$





# Distribuições marginais e condicionais

Analogamente ao caso discreto, as fdp marginais de  $X$  e de  $Y$  e as fdp condicionais de  $X$  e de  $Y$  são as seguintes

fdp marginais: (i) de  $X$  :

$$f_X(x) = \int_{-\infty}^{+\infty} f_{X,Y}(x, y) dy$$

(ii) de  $Y$  :

$$f_Y(y) = \int_{-\infty}^{+\infty} f_{X,Y}(x, y) dx$$

fdp condicionais: (i) de  $X$ , dado  $\{Y = y\}$  :

$$f_{X|Y=y}(x) = \frac{f_{X,Y}(x, y)}{f_Y(y)}$$

(ii) de  $Y$ , dado  $\{X = x\}$  :

$$f_{Y|X=x}(y) = \frac{f_{X,Y}(x, y)}{f_X(x)}$$

A independência entre  $X$  e  $Y$  equivale a ter  $f_{X,Y}(x, y) = f_X(x)f_Y(y)$

## Nota:


Se for possível factorizar a fdp conjunta  $f(x,y)$  na forma  $f(x,y) = g(x) h(y)$ ,  $(x,y) \in \mathbb{R}^2$  então temos que  $g$  e  $h$ , a menos de constantes multiplicativas, são as fdp marginais de  $X$  e  $Y$ . De facto,

$$f_X(x) = \int_{-\infty}^{+\infty} f(x,y)dy = \int_{-\infty}^{+\infty} g(x)h(y)dy = g(x) \int_{-\infty}^{+\infty} h(y)dy = c_1 g(x)$$

e analogamente

$$f_Y(y) = \int_{-\infty}^{+\infty} f(x,y)dx = \int_{-\infty}^{+\infty} g(x)h(y)dx = h(y) \int_{-\infty}^{+\infty} g(x)dx = c_2 h(y)$$

**Exemplo 24:** fdp conjunta de um par aleatório  $(X,Y)$  com distribuição uniforme no quadrado  $[0,1] \times [0,1]$ , i.e., com fdp conjunta



$$f(x, y) = I_{[0,1] \times [0,1]}(x, y)$$

ou

$$f(x, y) = \begin{cases} 1 & , 0 \leq x \leq 1, 0 \leq y \leq 1 \\ 0 & , c.c. \end{cases}$$

$X$  e  $Y$  são independentes pois a fdp conjunta é o produto de duas fdp  $U[0,1]$ , dadas por  $g(x) = I_{[0,1]}(x)$ . De facto, para  $(x, y) \in \mathbb{R}^2$  temos  $f(x, y) = g(x)g(y)$

## Valores médios\* (caso contínuo)

v.a.  $X$ :

$$E(h(X)) = \int_{-\infty}^{+\infty} h(x) f(x) dx$$

par  $(X, Y)$ :

$$E(h(X, Y)) = \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} h(x, y) f(x, y) dx dy$$

Tal como no caso discreto, a **covariância** entre  $X$  e  $Y$  é definida por

$$\text{cov}(X, Y) = E((X - \mu_X)(Y - \mu_Y)) = \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} (x - \mu_X)(y - \mu_Y) f(x, y) dx dy$$

e prova-se que  $\text{cov}(X, Y) = E(XY) - E(X)E(Y)$

---


\* existem somente se os integrais convergirem absolutamente

**Exemplo 25: (nº 54)**  $(X, Y)$  com fdp conjunta

$$f(x, y) = \begin{cases} 3x & , 0 \leq 2x \leq y \leq 2 \\ 0 & , \text{c.c.} \end{cases}$$

$X$  e  $Y$  não são independentes pois  $P(X > 0.5, Y < 1) = 0$  mas  $P(X > 0.5)$  e  $P(Y < 1)$  são positivas.

Cálculo das fdp marginais:



$$f_X(x) = \int_{-\infty}^{+\infty} f(x, y) dy = \int_{2x}^2 3x dy = 3xy \Big|_{2x}^2 = 3x(2 - 2x) = 6x(1 - x), \quad 0 < x < 1$$

$$f_Y(y) = \int_{-\infty}^{+\infty} f(x, y) dx = \int_0^{y/2} 3x dx = \frac{3}{2} x^2 \Big|_0^{y/2} = \frac{3}{2} \frac{1}{4} y^2 = \frac{3}{8} y^2, \quad 0 < y < 2$$

*Exemplo 25 (cont.):* Cálculo de valores médios e covariância:

$$E(X) = \int_{-\infty}^{+\infty} x f_X(x) dx = \int_0^1 6x^2(1-x) dx = \int_0^1 6x^2 - 6x^3 dx = \left(2x^3 - \frac{6}{4}x^4\right) \Big|_0^1 = \frac{1}{2}$$

$$E(Y) = \int_{-\infty}^{+\infty} y f_Y(y) dy = \int_0^2 \frac{3}{8} y^3 dy = \frac{3}{8} \frac{1}{4} y^4 \Big|_0^2 = \frac{3}{8} \frac{16}{4} = \frac{3}{2}$$

$$\begin{aligned} E(XY) &= \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} xy f(x, y) dx dy = \int_0^1 \left( \int_{2x}^2 3x^2 y dy \right) dx = 3 \int_0^1 \frac{1}{2} x^2 y^2 \Big|_{2x}^2 dx = \\ &= 3 \int_0^1 \frac{1}{2} x^2 (4 - 4x^2) dx = 3 \int_0^1 2x^2 - 2x^4 dx = \frac{6}{3} x^3 - \frac{6}{5} x^5 \Big|_0^1 = 2 - \frac{6}{5} = \frac{4}{5} \end{aligned}$$

$$\text{cov}(X, Y) = E(XY) - E(X)E(Y) = \frac{4}{5} - \frac{1}{2} \frac{3}{2} = \frac{1}{20}$$

## Valores médios, variâncias, etc. (resumo) \*

v.a.  $X$

$$E(h(X)) = \begin{cases} \sum_i h(x_i) p_i & \text{no c. discreto} \\ \int_{-\infty}^{+\infty} h(x) f(x) dx & \text{no c. contínuo} \end{cases}$$

par  $(X, Y)$

$$E(h(X, Y)) = \begin{cases} \sum_i \sum_j h(x_i, y_j) p_{ij} & \text{no c. discreto} \\ \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} h(x, y) f(x, y) dx dy & \text{no c. contínuo} \end{cases}$$

Em particular – valores médios, variâncias, covariância e correlação:

$$\mu_X = E(X), \quad \mu_Y = E(Y), \quad \sigma_X^2 = \text{var}(X), \quad \sigma_Y^2 = \text{var}(Y)$$

$$\text{cov}(X, Y) = E((X - \mu_X)(Y - \mu_Y)) ; \quad \rho(X, Y) = \frac{\text{cov}(X, Y)}{\sigma_X \sigma_Y}$$

$$\text{cov}(X, Y) = E(XY) - E(X)E(Y)$$

---

\* existem somente se as séries/integrais convergirem absolutamente

## Propriedades (v.a. quaisquer)

São válidas as propriedades 1.1 a 4.6 (slides 115 a 121). Em particular,

- $E(a + bX) = a + bE(X)$
- $\text{var}(a + bX) = b^2 \text{var}(X)$
- $E(X_1 + \dots + X_n) = E(X_1) + \dots + E(X_n)$
- $\text{var}(X_1 + \dots + X_n) = \sum_i \text{var}(X_i) + 2 \sum_{i < j} \text{cov}(X_i, X_j)$

Se  $X_1, \dots, X_n$  independentes, então  $\text{cov}(X_i, X_j) = 0$  e

- $\text{var}\left(\sum_{i=1}^n X_i\right) = \sum_{i=1}^n \text{var}(X_i)$
- $E(X_1 \dots X_n) = E(X_1) \dots E(X_n)$

- $\text{cov}(aX + bY, cU + dV) = ac \text{cov}(X, U) + ad \text{cov}(X, V) + bc \text{cov}(Y, U) + bd \text{cov}(Y, V)$   
(bilinearidade)



## Coeficiente de correlação entre duas v.a. (revisão)

Recorde-se que a correlação entre  $X$  e  $Y$  se define por

$$\rho = \rho(X, Y) = E\left(\frac{X - \mu_X}{\sigma_X} \frac{Y - \mu_Y}{\sigma_Y}\right) \quad \text{ou seja} \quad \rho = \frac{\text{cov}(X, Y)}{\sigma_X \sigma_Y}$$

(caso exista este valor médio) e satisfaz a

- $-1 \leq \rho \leq 1$
- $X$  e  $Y$  independentes  $\Rightarrow \rho = 0$  (a recíproca não é verdadeira)
- $\rho = \pm 1 \Leftrightarrow P(Y = a + bX) = 1$  para algum  $a \in \mathbb{R}$  e  $b \neq 0$
- é invariante para transformações lineares de  $X$  e de  $Y$   
(a menos do sinal)

$\rho$  mede a  
relação de  
linearidade  
entre  $X$  e  $Y$

## Propriedades (v.a. normais independentes)

Propriedades a demonstrar adiante usando transformadas de Laplace

Se  $X_i \sim N(\mu_i, \sigma_i)$  independentes,  $i = 1, 2, \dots, n$ , então

$$S_n \sim N\left(\sum \mu_i, \sqrt{\sum \sigma_i^2}\right)$$

$$\sum_{i=1}^n a_i X_i \sim N\left(\sum a_i \mu_i, \sqrt{\sum a_i^2 \sigma_i^2}\right)$$

Soma de v.a.

$$S_n = \sum_{i=1}^n X_i$$

Média de v.a.

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$

Em particular, se  $X_i \sim N(\mu, \sigma)$  independentes, então


$$S_n \sim N(n\mu, \sigma\sqrt{n})$$

$$\bar{X} \sim N\left(\mu, \frac{\sigma}{\sqrt{n}}\right)$$


# Distribuição normal bivariada (ou gaussiana bivariada ou binormal)

com parâmetros  $\mu, \mu', \sigma, \sigma', \rho$

gráficos das fdp's conjuntas  
( $\mu = \mu' = 0, \sigma = \sigma' = 1$ )





$\rho = 0$



$\rho = 0.8$

e curvas de nível  
( $\mu = \mu' = 0, \sigma = \sigma' = 1$ )



A fdp conjunta de um par  $(X,Y)$  binormal com parâmetros  $\mu, \mu', \sigma, \sigma', \rho$  (que representam os valores médios e desvios padrões de  $X$  e  $Y$  e a correlação entre  $X$  e  $Y$ ) é dada por

$$f(x, y) = \frac{1}{2\pi\sigma\sigma'\sqrt{1-\rho^2}} \exp\left\{-\frac{1}{2(1-\rho^2)}(x'^2 - 2\rho x' y' + y'^2)\right\}, \text{ com } \begin{cases} x' = \frac{x-\mu}{\sigma} \\ y' = \frac{y-\mu'}{\sigma'} \end{cases}$$

Neste modelo temos:

- (i)  $X \sim N(\mu, \sigma)$  e  $Y \sim N(\mu', \sigma')$
- (ii)  $\rho = 0 \iff X$  e  $Y$  independentes
- (iii) Qualquer transformação linear do par é também binormal

---

**Nota:** o caso  $\rho^2 = 1$  corresponde a uma distribuição concentrada numa recta,  $y = a + b x$  (com  $b \neq 0$ ), pelo que o suporte do par é uma recta (subconjunto unidimensional de  $\mathbb{R}^2$ , dito degenerado a duas dimensões). A distribuição diz-se bivariada singular ou degenerada a duas dimensões.

(i) Cálculo da fdp marginal de  $X$ , no caso  $(X,Y)$  binormal com parâmetros  $\mu, \mu', \sigma, \sigma', \rho$

$$f(x, y) = \frac{1}{2\pi\sigma\sigma'\sqrt{1-\rho^2}} \exp\left\{-\frac{1}{2(1-\rho^2)} \underbrace{(x'^2 - 2\rho x' y' + y'^2)}_{(1-\rho^2)x'^2 + \rho^2 x'^2 - 2\rho x' y' + y'^2}\right\}$$

$$\left\{ \begin{array}{l} x' = \frac{x-\mu}{\sigma} \\ y' = \frac{y-\mu'}{\sigma'} \end{array} \right.$$

$$(1-\rho^2)x'^2 + (y' - \rho x')^2$$

$$(1-\rho^2)x'^2 + \left(y - [\mu' + \rho \frac{\sigma'}{\sigma}(x - \mu)]\right)^2 / \sigma'^2$$

$$f(x, y) = \underbrace{\frac{1}{\sigma\sqrt{2\pi}} e^{-x'^2/2}}_{\text{fdp } N(\mu, \sigma)} \underbrace{\frac{1}{\sigma'\sqrt{2\pi}\sqrt{1-\rho^2}} e^{-\frac{1}{2(1-\rho^2)\sigma'^2} \left(y - [\mu' + \rho \frac{\sigma'}{\sigma}(x - \mu)]\right)^2}}_{\text{fdp } N\left(\mu' + \rho \frac{\sigma'}{\sigma}(x - \mu), \sigma'\sqrt{1-\rho^2}\right)} \Rightarrow f_X(x) = \int_{-\infty}^{+\infty} f(x, y) dy =$$

$$= \frac{1}{\sigma\sqrt{2\pi}} e^{-x'^2/2}$$

$\therefore X \sim N(\mu, \sigma)$

## Simulação de par aleatório binormal ( $\mu = 1, \mu' = 2, \sigma = 2, \sigma' = 3, \rho = 0.8$ )

package

mvtnorm

função

rmvnorm(n=..., mean=c(..., ...), sigma=...)

nº simulações


$\mu$

$\mu'$

matriz de  
covariâncias

Por exemplo,

```
library(mvtnorm)
sig <- matrix(c(4,4.8,4.8,9), ncol=2)
x <- rmvnorm(1000, c(1,2), sig)
colMeans(x)
[1] 0.9991239 1.9673403
var(x)
 3.797903 4.600176
 4.600176 8.823428
cor(x)
 1.0000000 0.7946646
 0.7946646 1.0000000
plot(x, xlab="x", ylab="y", las=1)
abline(h=2, col=4, lty=2)
abline(v=1, col=4, lty=2)
```



$$\Sigma = \begin{pmatrix} \sigma^2 & \text{cov} \\ \text{cov} & \sigma'^2 \end{pmatrix}$$

$$\begin{pmatrix} 4 & 4.8 \\ 4.8 & 9 \end{pmatrix}$$

$$\rho = \frac{4.8}{2 \times 3} = 0.8$$

# Exercícios resolvidos

**Exercício: (nº 57)** Qual a distribuição de  $X - Y$  no caso  $(X, Y)$  binormal?

**Resolução:** Como qualquer transformação linear de um par binormal é também binormal, temos (atendendo a que as marginais de um par binormal são normais) que  $X - Y$  é normal.

Falta apenas identificar os parâmetros, ou seja, calcular o valor médio e a variância de  $X - Y$ .

$$E(X - Y) = E(X) - E(Y) = \mu - \mu'$$

$$\text{var}(X - Y) = \text{var}(X) + \text{var}(Y) - 2 \text{cov}(X, Y) = \sigma^2 + \sigma'^2 - 2\rho\sigma\sigma'$$

Conclui-se que  $X - Y$  tem distribuição  $N(\mu - \mu', \tau)$ ,  $\tau^2 = \sigma^2 + \sigma'^2 - 2\rho\sigma\sigma'$



**Exercício: (nº 58)** (i) Calcule a distribuição de  $Y = Z^2$  no caso  $Z \sim N(0,1)$ .  
(ii) Por meio de simulação, tente descobrir qual a distribuição da soma de duas v.a. independentes  $Y_1$  e  $Y_2$  (sendo  $Y_i = Z_i^2$ ).

**Resolução:** (i) Representa-se usualmente a fd [ fdp ] de  $Z$  pela letra  $\Phi$  [  $\phi$  ].  
Para  $y > 0$  temos

$$F_Y(y) = P(Y \leq y) = P(Z^2 \leq y) = P(-\sqrt{y} \leq Z \leq \sqrt{y}) = \Phi(\sqrt{y}) - \Phi(-\sqrt{y})$$


donde

$$\begin{aligned} f_Y(y) &= \frac{d}{dy} F_Y(y) = \frac{d}{dy} \Phi(\sqrt{y}) - \frac{d}{dy} \Phi(-\sqrt{y}) = \phi(\sqrt{y}) \frac{1}{2\sqrt{y}} + \phi(-\sqrt{y}) \frac{1}{2\sqrt{y}} = \\ &= \phi(\sqrt{y}) \frac{1}{\sqrt{y}} = \frac{1}{\sqrt{2\pi}} \frac{1}{\sqrt{y}} e^{-y/2}, \quad y > 0 \end{aligned}$$

**Exercício: (ii)** Por meio de simulação, tente descobrir qual a distribuição da soma de duas v.a. independentes  $Y_1$  e  $Y_2$ , com a mesma distribuição de  $Y = Z^2$  (diz-se que  $Y_1$  e  $Y_2$  são **independentes e identicamente distribuídas (i.i.d.)** com  $Y$ ).

**Resolução: (ii)**

```
# simular 2 amostras de 10^6 n°s N(0,1):  
x <- rnorm(10^6)  
y <- rnorm(10^6)  
# amostra da soma dos seus quadrados:  
t <- x^2 + y^2  
# histograma de área unitária:  
hist(t,50,freq=F, main="")  
# parece uma fdp exponencial com f(0)≈0.5;  
# sobrepor gráfico da fdp Exp(1/2):  
curve(dexp(x,1/2),0,30,add=T,col=2)  
# ou o histograma num único comando, etc.:  
hist(rnorm(10^6)^2+rnorm(10^6)^2,50,freq=F,main="",xlab="t",ylab="freq / fdp")  
# A estimativa  $\lambda=1/2$  também decorre de ser  $\text{mean}(t) \approx 2$ , que estima  $E(X)=1/\lambda$ 
```



# Transformação uniformizante

Dada uma v.a.  $X$  com fd contínua  $F(\cdot)$ , então  $Y = F(X) \frown U[0,1]$ , i.e.,  $F_Y(y) = \begin{cases} 0 & , y < 0 \\ y & , 0 \leq y < 1 \\ 1 & , y \geq 1 \end{cases}$   
Reciprocamente, se  $Y \frown U[0,1]$ , então  $X = F^{-1}(Y)$  tem fd  $F(\cdot)$ .

**Demonstração:** Note-se que sendo  $F$  contínua, o seu contradomínio é o intervalo de 0 a 1, donde temos  $F_Y(y) = 0$ , para  $y < 0$  e  $F_Y(y) = 1$  para  $y > 1$ . Determina-se então  $F_Y(y)$ , para  $0 < y < 1$ :

$$F_Y(y) = P(Y \leq y) = P(F(X) \leq y) = P(X \leq F^{-1}(y)) = F(F^{-1}(y)) = y$$

Logo  $Y = F(X) \frown U[0,1]$ .

$\downarrow$   
 $F$  é não decrescente

Reciprocamente,  $P(X \leq x) = P(F^{-1}(Y) \leq x) \overset{\uparrow}{=} P(Y \leq F(x)) = F(x)$

---

**Nota:** Este resultado está na origem do método de “inversão da fd” para geração de NPAs com dada distribuição contínua, a partir de NPAs uniformes.

**Exercício: (nº 59)** Aplique a transformação uniformizante ao caso  $X \sim \text{Exp}(\lambda)$ , simulando uma amostra de dados  $\text{Exp}(2)$ , a partir de dados  $U[0,1]$ .

**Resolução:** Neste caso  $F(x) = (1 - e^{-\lambda x}) I_{[0,+\infty[}(x)$  é uma função contínua, donde  $F(X) \sim U(0,1)$ . Temos ainda  $F^{-1}(y) = -\frac{1}{\lambda} \log(1 - y)$ ,  $0 < y < 1$ , pois  $y = 1 - e^{-\lambda x} \Leftrightarrow e^{-\lambda x} = 1 - y \Leftrightarrow -\lambda x = \log(1 - y) \Leftrightarrow x = -\frac{1}{\lambda} \log(1 - y)$

Logo, a partir de uma amostra de dados  $y$  com distribuição  $U(0,1)$  obtemos uma amostra  $\text{Exp}(\lambda)$  fazendo  $x \leftarrow -\log(1 - y) / \lambda$

```
y <- runif(10000)
x <- -log(1-y)/2
hist(x, 50, freq=F, main="", las=1)
curve(dexp(x, 2), 0, col=2, add=T)
```

